ARCHITECTURE D'ENTREPRISE • SYSTÈMES MULTI-AGENTS • STANDARDS 2027

Interopérabilité et Orchestration en Entreprise Agentique

Compendium 2027 — Architecture, Protocoles, Exécution Durable et Gouvernance à Grande Échelle

Périmètre de référence (500 pages) : Pile ouverte Linux Foundation AAIF (`MCP`, `A2A v1.0`, `Agent Skills`, `agentgateway`, `OpenSandbox`, `OpenEnv`) • Réseau `AGNTCY` (`OASF`, `SLIM`) • Sémantique `Apache Ossie` & mémoire bi-temporelle • Exécution durable (`Temporal`, `Restate`, `Saga`) • Fédération SaaS, `CUA` & convergence `IT/OT` (`OPC-UA`) • Identité Zero Trust (`OAuth 2.1 OBO`, `OWASP ASI01–ASI10`) • `OpenTelemetry GenAI`, τ-bench, FinOps & Conformité 2027 (`ISO/IEC 42001`, `BSIF E-23`, `Loi 25`, `EU AI Act`).

Édition de Référence — Architecture d'Entreprise Agentique

Compendium Technique & Stratégique (Horizon 2027)

Édition 2027

Table des matières

Ouverture — Architecture et Gouvernance du Tissu Conjonctif Agentique en 2027 1
0.1 Pourquoi ce compendium en 2027 : la fin des silos d'assistants et l'impératif du tissu conjonctif 1
0.2 L'équation économique et opérationnelle de 2027 : la poursuite et le péril du contrôle 4
0.3 Parcours de lecture opérationnels par rôle 6
0.4 Conventions architecturales, échelle d'autonomie et rigueur épistémique 9
0.5 Dossier initial du fil rouge : Groupe Boréal Inc. 12
0.6 Cartographie synthétique des standards, protocoles et cadres de référence 2027 14
PARTIE I — Fondations de l'Entreprise Agentique en 2027 : Paradigmes, Taxonomie et Maturité 18
Chapitre 1 — De l'assistance conversationnelle à la main-d'œuvre d'exécution asynchrone 19
1.1 Anatomie évolutive (2023–2027) : pourquoi le paradigme du copilote plafonne en entreprise 19
1.2 Taxonomie fonctionnelle des acteurs numériques en entreprise 23
1.3 Du *UI-First* au *System of Action* : refonder la stratigraphie du système d'information 27
1.4 Anatomie du cycle d'exécution asynchrone : régimes temporels et bascule *Human-on-the-Loop* 34
1.5 Application au fil rouge : premier flux transversal chez Groupe Boréal . 36
1.6 Décision d'architecture normative et points de contrôle 38

Ouverture — Architecture et Gouvernance du Tissu Conjonctif Agentique en 2027

SYNTHÈSE EXÉCUTIVE

Portée exécutive de l'Ouverture (Cadrage du Compendium — 500 pages)

- **Constat fondamental** : En 2027, la performance d'une entreprise agentique ne dépend plus de la supériorité intrinsèque d'un grand modèle de langage pris isolément, mais de la robustesse du **tissu conjonctif** qui relie ses agents spécialisés, ses progiciels patrimoniaux, ses équipements physiques et ses superviseurs humains.
- **Thèse architecturale** : Industrialiser l'autonomie exige de conjuguer deux disciplines complémentaires — une **interopérabilité ouverte en six couches** (transport, outils, coordination entre pairs, interfaces, sémantique métier, transactions) et une **orchestration hybride** qui ancre des cellules de raisonnement probabiliste à l'intérieur de plans de contrôle déterministes et durables.
- **Usage de l'ouvrage** : Cette ouverture établit l'architecture de référence globale du compendium, fournit six parcours de lecture ciblés par fonction dirigeante ou technique, normalise l'échelle des niveaux d'autonomie (`L0` à `L4`) et pose le dossier initial de l'entreprise fil rouge (**Groupe Boréal Inc.**) suivie tout au long des 25 chapitres.

0.1 Pourquoi ce compendium en 2027 : la fin des silos d'assistants et l'impératif du tissu conjonctif

Entre 2023 et 2025, la première vague d'adoption de l'intelligence artificielle générative en entreprise s'est organisée autour d'une figure dominante : l'assistant conversationnel synchrone. Qu'il prenne la forme d'un clavardoir interne branché sur une base documentaire par génération augmentée de récupération (*Retrieval-Augmented Generation*, RAG) ou d'un copilote intégré à une suite bureautique, ce dispositif conservait une propriété architecturale rassurante : **l'être humain demeurait l'unique bus d'intégration du système d'information**. Lorsqu'un copilote résumait un contrat, suggérait une requête SQL ou rédigeait un avis d'incident, un opérateur humain lisait la proposition à l'écran, en validait

implicitement la cohérence métier, puis copiait ou saisissait lui-même la décision dans l'ERP, le CRM ou le système de gestion des services TI.

Au cours de l'année 2026, ce centre de gravité a basculé. Poussées par la recherche de gains de productivité mesurables sur des processus de bout en bout, les organisations ont franchi la frontière séparant la génération de texte de l'**exécution autonome d'actions**. Les systèmes déployés à l'horizon 2027 planifient des séquences multi-étapes, invoquent des outils externes, délèguent des sous-mandats à d'autres agents spécialisés, maintiennent un état sur plusieurs jours et écrivent directement dans des systèmes d'enregistrement (*Systems of Record*).

Or, le passage à l'échelle de ces premiers déploiements a révélé une fracture brutale entre la facilité apparente d'un prototype de laboratoire et les exigences d'ingénierie d'un système distribué d'entreprise. Trois phénomènes convergents expliquent pourquoi **l'interopérabilité** et **l'orchestration** constituent désormais la préoccupation cardinale des architectes et des directions technologiques :

1. **La prolifération d'îlots agentiques incompatibles (*Agent Sprawl*)**. Chaque grand éditeur de progiciels d'entreprise a doté sa plateforme de son propre moteur d'agents — `Salesforce Agentforce` autour de la relation client, `ServiceNow AI Agents` pour les flux opérationnels et TI, `SAP Joule` au cœur des ressources d'entreprise et de la chaîne d'approvisionnement, `Microsoft Copilot Studio` dans l'environnement collaboratif, `Workday Illuminate` pour le capital humain — tandis que les équipes d'ingénierie internes bâtissaient en parallèle des agents sur mesure sur des cadriciels variés. Sans couche d'interopérabilité normalisée, l'entreprise remplace simplement ses anciens silos applicatifs par des silos cognitifs bavards, incapables de se transmettre un contexte fiable, une identité vérifiable ou une transaction compensable.
2. **La consolidation historique des standards ouverts**. Ce qui n'était fin 2024 qu'une mosaïque de propositions propriétaires concurrentes s'est structuré, à compter de décembre 2025 et tout au long de 2026, sous une gouvernance neutre principalement hébergée par l'**Agentic AI Foundation (AAIF)** de la Linux Foundation (fédérant plus de 300 organisations membres fin 2026), en synergie avec le projet **AGNTCY**, l'Apache Software Foundation, le W3C, l'IETF et la FIDO Alliance. L'industrie dispose désormais d'une séparation architecturale claire entre la connectivité verticale aux outils et données (`Model Context Protocol`, `MCP`), la coordination horizontale entre agents pairs

(`Agent2Agent`, `A2A v1.0`, dans lequel s'est fondu `ACP`), le partage sémantique métier (`Apache Ossie`), le plan de données (`agentgateway`) et l'autorisation transactionnelle (`AP2`, `x402`).

3. **L'entrée en vigueur simultanée d'exigences réglementaires et fiduciaires strictes**. L'année 2027 ferme définitivement la parenthèse de tolérance expérimentale. Au Canada, la ligne directrice **E-23 révisée du Bureau du surintendant des institutions financières (BSIF / OSFI)** sur la gestion du risque de modèle entre en vigueur le **1er mai 2027**, assujettissant explicitement les systèmes d'IA générative et agentique à un inventaire exhaustif, à une cotation de matérialité et à une validation rigoureuse du cycle de vie. Au Québec, le régime pleinement actif de la **Loi 25** encadre sévèrement les décisions exclusivement automatisées (article 12.1), les évaluations des facteurs relatifs à la vie privée (ÉFVP) et les transferts transfrontaliers de renseignements personnels, sous peine de sanctions atteignant 25 M$ CAD ou 4 % du chiffre d'affaires mondial. En Europe, après l'activation des obligations de transparence de l'article 50 en août 2026, l'**EU AI Act** converge vers l'échéance de **décembre 2027** pour les systèmes à haut risque, tandis que la norme **ISO/IEC 42001** s'impose comme référentiel certifiable de gouvernance dans les appels d'offres B2B.

Ce compendium de 500 pages part d'un postulat d'ingénierie sans concession : **les modèles fondationnels sont devenus des composants interchangeables à obsolescence rapide, tandis que l'architecture d'interopérabilité, d'orchestration, de sémantique et de sécurité forme l'infrastructure pérenne de l'entreprise agentique**.

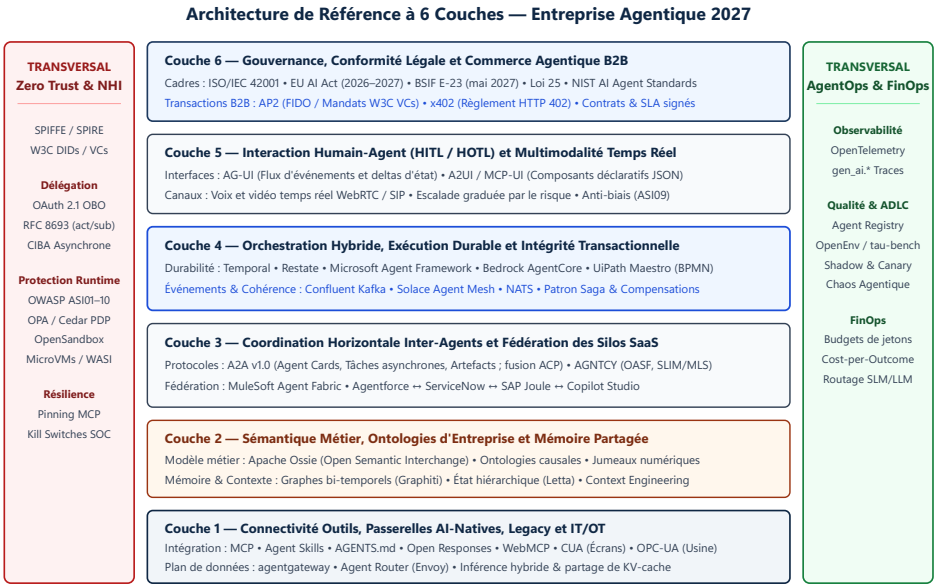


Fig. 1. – Architecture de référence à 6 couches et 2 piliers transversaux de l'entreprise agentique en 2027.

La figure ci-dessus synthétise le modèle de référence qui charpente les huit parties de cet ouvrage. Plutôt que de traiter un agent comme une boîte magique autosuffisante, cette architecture décompose le système en **six couches horizontales composables** traversées de haut en bas par **deux colonnes vertébrales non négociables** : à gauche, le contrôle d'identité non humaine (`NHI`) et la sécurité Zero Trust ; à droite, l'observabilité distribuée (`OpenTelemetry gen_ai.*`), le génie logiciel probabiliste (`AgentOps`) et la gouvernance économique (`FinOps`).

0.2 L'équation économique et opérationnelle de 2027 : la poursuite et le péril du contrôle

Les analyses convergentes publiées par les grands cabinets d'évaluation technologique à l'aube de 2027 — résumées par la formule de Forrester qualifiant 2027 d'ère de *« la poursuite et du péril du contrôle »* (*The Pursuit and Peril of Control*) et par les mises en garde de Gartner sur la dérive des coûts variables — mettent en évidence un paradoxe majeur : plus les agents individuels gagnent en spécialisa-

tion et en autonomie locale, plus le système global devient vulnérable au désordre de coordination.

Trois écueils structurels menacent tout programme d'entreprise qui aborde l'orchestration multi-agents avec les habitudes du développement web traditionnel ou des premiers prototypes LLM :

- **L'effondrement de la fiabilité par composition probabiliste**. Si un agent autonome réussit une étape complexe avec une exactitude remarquable de 94 %, une chaîne séquentielle non encadrée de dix délégations successives voit sa probabilité de succès sans erreur tomber à $0,94^{10} \approx 53,9\,\%$. Pire encore, contrairement à un microservice classique qui échoue bruyamment par une exception HTTP 500, un maillon LLM défaillant produit fréquemment une rationalisation plausible qui contamine silencieusement les agents aval (`OWASP ASI08` — *Cascading Failures*). La fiabilité d'entreprise exige par conséquent d'extraire le routage critique, les invariants d'affaires et la gestion d'état hors du prompt, pour les confier à une épine dorsale déterministe et durable.
- **L'impasse de l'interopérabilité purement syntaxique**. Normaliser le format d'échange par JSON-RPC (`MCP`) ou par descripteurs de tâches (`A2A`) résout le problème du *tuyau*, nullement celui du *sens*. Lorsqu'un agent commercial interroge un agent financier sur le « taux d'attrition trimestriel » ou l'« exposition nette d'un client », l'absence d'une couche sémantique partagée (`Apache Ossie`) et d'une ontologie causale d'entreprise engendre des décisions incohérentes mais syntaxiquement valides. L'interopérabilité réelle est indissociable de l'ingénierie du contexte (*Context Engineering*) et de la gouvernance mémorielle.
- **L'asymétrie économique et sécuritaire des boucles autonomes**. Une requête humaine mal formulée coûte quelques centimes ; une boucle de réessai mutuelle entre deux agents mal orchestrés consommant du calcul d'inférence réflexif (*test-time compute*) pendant une fin de semaine peut engloutir des dizaines de milliers de dollars et saturer les quotas d'API d'un système ERP critique. De même, confier à un agent les privilèges complets de l'utilisateur qui l'invoque transforme la moindre injection de prompt indirecte cachée dans un courriel ou un document externe en brèche d'exfiltration massive.

Le tableau suivant récapitule les sept ruptures architecturales qui séparent les pratiques héritées des prototypes 2024–2025 des standards de production 2027 détaillés dans ce compendium.

Axe d'architecture	Pratique prototype héritée (2024–2025)	Standard de production d'entreprise (2027)	Parties de référence
Modèle d'interaction	Clavardage synchrone déclenché et validé manuellement par l'utilisateur	Exécution asynchrone pilotée par événements, supervisée en *Human-on-the-Loop* (`HOTL`)	Parties I & IV
Intégration aux outils et pairs	Connecteurs REST ad hoc codés en dur par cadriciel, prompts collés	Pile ouverte bi-couche : `MCP` + `Agent Skills` (vertical) et `A2A v1.0` + `AGNTCY` (horizontal)	Partie II
Contexte et mémoire	RAG vectoriel plat sur documents bruts ; historique de conversation tronqué	*Context Engineering*, sémantique `Apache Ossie`, ontologies et graphes bi-temporels (`Graphiti`)	Partie III
Contrôle de flux et état	Le LLM décide seul de l'enchaînement en mémoire vive volatile	Épine dorsale durable (`Temporal`, `Restate`), maillage `Kafka`/`Solace` et compensations `Saga`	Partie IV
Patrimoine SaaS, Legacy et OT	Agents captifs d'un seul éditeur ; systèmes sans API et ateliers ignorés	Gravité des données, plan de contrôle fédéré, `CUA` confinés et sas `OPC-UA` / Jumeau numérique	Partie V
Identité et sécurité	Clés d'API statiques partagées ou jeton brut de l'utilisateur humain	Identités `NHI` (`SPIFFE/DID`), `OAuth 2.1 OBO` (`RFC 8693`), `OpenSandbox` et politiques `Cedar/OPA`	Partie VI
Opérations, coûts et conformité	Journaux texte locaux, tests manuels sur 10 exemples, budget infonuagique global	Traces `OpenTelemetry gen_ai.*`, simulation τ-bench (pass^k), *Cost-per-Outcome*, `ISO 42001` / `E-23`	Parties VII & VIII

0.3 Parcours de lecture opérationnels par rôle

Un ouvrage de 500 pages couvrant aussi bien la négociation cryptographique de jetons `RFC 8693` que la modélisation ontologique ou le droit des contrats B2B ne se lit pas nécessairement de manière linéaire du premier au dernier chapitre. Bien que l'ordre des huit parties suive une progression logique ascendante —

des fondations conceptuelles jusqu'à la gouvernance exécutive —, six parcours prioritaires ont été conçus pour répondre aux mandats immédiats des décideurs et spécialistes.

1. Parcours CTO / CIO (Direction technologique et stratégie de plateforme)

- **Question directrice** : *Comment éviter la balkanisation de notre SI en dix plateformes d'agents concurrentes tout en maîtrisant le TCO et la vélocité de livraison ?*
- **Séquence prioritaire** : **Chapitres 1, 2 et 3** (vision cible, découplage contrôle/autonomie, modèle de maturité N1–N5) ⟶ **Chapitre 4** (gouvernance AAIF et stratégie anti-verrouillage) ⟶ **Chapitre 14** (passerelles AI-natives et routage hybride `SLM`/`LLM`) ⟶ **Chapitre 15** (fédération des jardins clos SaaS et principe de gravité des données) ⟶ **Chapitres 23 et 25** (FinOps *Cost-per-Outcome* et modèle opérationnel du Centre d'Excellence Agentique).
- **Livrables directement réutilisables** : Grille d'audit de maturité, politique d'allocation budgétaire par résultat métier et fiches `ADR-001`, `ADR-004`, `ADR-015` et `ADR-023`.

2. Parcours Architecte d'entreprise et Architecte de solutions principales

- **Question directrice** : *Quels patrons de communication, de gestion d'état et d'intégrité transactionnelle garantissent la résilience de flux multi-agents traversant des systèmes hétérogènes ?*
- **Séquence prioritaire** : Lecture intégrale des **Parties I, II, IV et V** (**Chapitres 1 à 7** puis **Chapitres 11 à 17**), complétée par le **Chapitre 9** (`Apache Ossie` et ontologies) et l'**Annexe A** (arbres de décision architecturale).
- **Point d'attention particulier** : Les **Chapitres 12 et 13** sur l'articulation entre moteurs d'exécution durable (`Temporal`, `Restate`) et sagas événementielles à compensation sur `Kafka` / `Solace`, qui constituent le cœur névralgique de la mise en production.

3. Parcours CISO, Architecte IAM et Responsable Cybersécurité

- **Question directrice** : *Comment gouverner des milliers d'identités non humaines dynamiques, prévenir l'empoisonnement d'outils `MCP` et conserver un coupe-circuit instantané ?*

- **Séquence prioritaire** : **Chapitre 2** (bornes déterministes) → **Chapitres 5 et 6** (surfaces protocolaires `MCP`, `A2A` et chiffrement `SLIM`/MLS) → lecture approfondie de la **Partie VI complète (Chapitres 18, 19 et 20)** → **Chapitre 21** (auditabilité `OpenTelemetry` sans fuite PII) → **Annexe B.1** (liste de contrôle Zero Trust).
- **Livrables directement réutilisables** : Architecture d'échange de jetons `OAuth 2.1 OBO` à portée atténuée, matrice de couverture `OWASP ASI01–ASI10`, politique d'épinglage cryptographique des serveurs `MCP` et patron d'isolation en microVM.

4. Parcours Responsable Plateforme, SRE Agentique et Ingénieur AgentOps

- **Question directrice** : *Comment instrumenter, tester avant déploiement, simuler sous chaos et opérer en continu des systèmes dont le comportement n'est pas déterministe ?*
- **Séquence prioritaire** : **Chapitres 12 et 14** (runtimes durables, `agentgateway`, ordonnancement `KV-cache`) → **Chapitre 20** (`OpenSandbox`, politiques en ligne) → **Partie VII complète (Chapitres 21, 22 et 23)** → **Annexe B.2 et B.3**.
- **Livrables directement réutilisables** : Schéma de télémétrie `gen_ai.*`, pipeline CI/CD `ADLC` intégrant `OpenEnv` et des portes d'homologation pass^k de type τ-bench, protocole de déploiement *Shadow/Canary* et règles de coupe-circuit budgétaire.

5. Parcours CDO, Architecte de Données et Ingénieur Contexte / Sémantique

- **Question directrice** : *Comment transformer nos entrepôts, graphes documentaires et couches BI en un modèle du monde cohérent et non contradictoire pour tous nos agents ?*
- **Séquence prioritaire** : **Chapitre 1** (*Systems of Record* vs *Systems of Action*) → **Partie III complète (Chapitres 8, 9 et 10)** → **Chapitre 15** (gravité des données) → **Chapitre 17** (jumeaux numériques et données `OPC-UA`) → **Chapitre 24** (résidence des données et `Loi 25`).

6. Parcours Direction Juridique, Conformité, Risques et Audit Interne

- **Question directrice** : *Comment démontrer la conformité de nos agents devant le BSIF, la Commission d'accès à l'information du Québec ou les régulateurs européens, et encadrer juridiquement les actes posés par nos agents ?*
- **Séquence prioritaire** : **Ouverture (Section 0.4) → Chapitre 3** (gouvernance de l'IA fantôme) → **Chapitre 7** (mandats vérifiables `AP2`) → **Chapitre 18** (traçabilité nominative de la chaîne de délégation) → **Partie VIII complète (Chapitres 24 et 25) → Annexe B.4**.

0.4 Conventions architecturales, échelle d'autonomie et rigueur épistémique

Pour éviter le flou terminologique qui mine nombre de comités d'architecture — où le même mot « agent » désigne tantôt un simple classifieur de texte, tantôt un système autonome habilité à passer des commandes fournisseurs —, tout le compendium applique une échelle normative unique en **cinq niveaux d'autonomie opérationnelle (`L0` à `L4`)**. Contrairement aux taxonomies purement cognitives, cette échelle est définie par les **droits de mutation sur le système d'information**, le **régime de supervision humaine** et les **contrôles d'infrastructure exigés**.

Niveau	Désignation normative	Droits sur les *Systems of Record*	Régime de supervision humaine	Exigences minimales d'orchestration et d'identité
L0	**Exécution déterministe pure** (API, règle DMN, robot RPA fixe)	Lecture/écriture strictement codées d'avance, zéro inférence	Aucune en exécution nominale (audit classique)	Compte de charge de travail (`Workload Identity`), journalisation standard
L1	**Assistance consultative** (Copilote synchrone, RAG analytique)	**Lecture seule** (filtrée par les droits `ACL` de l'utilisateur)	**Humain exécuteur** : l'humain lit et saisit toute action	Jeton délégué en lecture seule, masquage PII, télémétrie de base
L2	**Automatisation sous approbation préalable** (*Human-in-the-Loop*, `HITL`)	**Préparation d'écriture** (brouillon de tran-	**Approbation synchrone ou asynchrone ex-**	État durable (`awakeable`), identité `NHI` + `OBO`, protection anti-biais `ASI09`

Niveau	Désignation normative	Droits sur les *Systems of Record*	Régime de supervision humaine	Exigences minimales d'orchestration et d'identité
		saction en tampon)	**plicite** avant commit	
L3	**Autonomie bornée sous supervision par exception** (*Human-on-the-Loop*, `HOTL`)	**Écriture directe dans une enveloppe bornée** (seuils, périmètre, quotas)	**Escalade sur seuil de risque (`CIBA`)** et audit continu	Moteur durable, patron `Saga` compensable, PDP `Cedar`/`OPA` en ligne, coupe-circuit
L4	**Orchestration inter-agents et B2B fédérée**	**Négociation et exécution multi-domaines ou inter-entreprises**	**Gouvernance par politique et mandats cryptographiques**	`A2A v1.0` signé, mandats vérifiables `AP2`, attestation `SPIFFE`/`DID`, traces non répudiables

IMPORTANT

Règle d'attribution du niveau d'autonomie dans une chaîne multi-agents

Lorsqu'un orchestrateur coordonne plusieurs agents spécialistes, **le niveau d'exigence sécuritaire et réglementaire de la chaîne entière est dicté par le maillon possédant l'empreinte d'action la plus élevée** (*High-Water Mark Rule*). Un agent de niveau `L1` qui transmet une synthèse non assainie à un agent de niveau `L3` fait partie intégrante du périmètre de sécurité `L3` au regard du risque de détournement d'objectif (`OWASP ASI01`) et de la conformité réglementaire (`BSIF E-23`, `EU AI Act`).

Critères d'évaluation technologique utilisés dans l'ouvrage

Chaque fois que le compendium compare des protocoles, des moteurs d'orchestration ou des architectures de mémoire (Parties II à VII), l'analyse s'appuie sur cinq critères explicites plutôt que sur la popularité médiatique d'un outil :

1. **Gouvernance et neutralité fournisseur** : La spécification appartient-elle à une fondation ouverte multi-acteurs (Linux Foundation AAIF, ASF, IETF, W3C, FIDO) ou dépend-elle de la feuille de route commerciale d'un éditeur unique ?

2. **Déterminisme des frontières et auditabilité** : Peut-on reconstruire après coup, devant un auditeur interne ou un régulateur externe, l'état exact, l'identité délégante, la version de politique et les entrées qui ont conduit à une mutation ?
3. **Tolérance aux pannes et sémantique de reprise** : Que se passe-t-il concrètement si un nœud de calcul disparaît ou si une API externe expire à la septième étape d'un processus de dix étapes ?
4. **Coût marginal en latence et en jetons** : Quel est le multiplicateur d'appels LLM, la surcharge de sérialisation et l'impact sur la réutilisation du `KV-cache` lorsque le volume passe de dix requêtes par jour à dix mille par heure ?
5. **Coût de sortie (*Exit Cost*)** : Quel effort d'ingénierie faut-il fournir pour remplacer le modèle sous-jacent, changer de fournisseur infonuagique ou substituer un agent spécialiste sans réécrire le plan d'orchestration ?

Discipline épistémique : faits vérifiés vs projections 2027

Rédiger un compendium de référence pour 2027 impose de distinguer sans ambiguïté ce qui fonctionne déjà à l'échelle industrielle de ce qui émerge. Dans l'ensemble des chapitres :

- Les **protocoles, fondations, cadres de sécurité et produits** présentés comme socles d'architecture (`MCP`, `A2A v1.0`, les dix projets initiaux de l'`AAIF`, la pile `AGNTCY`, `Apache Ossie`, `OpenTelemetry gen_ai.*`, `OWASP ASI01–ASI10`, la famille τ-bench, `Temporal`, `Restate`, `Microsoft Agent Framework`, `Bedrock AgentCore`, `MuleSoft Agent Fabric`, `UiPath Maestro`) correspondent à des **réalités techniques vérifiées et documentées fin 2026**.
- Les **échéances juridiques** (`BSIF E-23` au 1er mai 2027, `EU AI Act` Annexe III en décembre 2027, obligations actives de la `Loi 25` et de l'article 50 européen) reposent sur les textes officiels en vigueur ; le texte signale systématiquement les zones où des guides d'application sectoriels demeurent attendus.
- Les **pratiques d'avant-garde** — au premier rang desquelles la contractualisation B2B entièrement autonome d'entreprise à entreprise via `AP2` et `x402` ou l'auto-assemblage dynamique d'essaims sans topologie pré-approuvée — sont explicitement balisées comme des **frontières émergentes**, accompagnées des verrous juridiques et prudentiels qui en limitent encore le déploiement généralisé.

0.5 Dossier initial du fil rouge : Groupe Boréal Inc.

Les concepts d'interopérabilité et d'orchestration ne révèlent leur véritable difficulté qu'au contact d'un système d'information patrimonial (*brownfield*), forgé par des décennies d'acquisitions, de dettes techniques et d'obligations légales hétérogènes. Pour éviter l'écueil des exemples jouets limités à trois fonctions Python idéalisées, les 25 chapitres de ce compendium suivent la transformation d'une entreprise de référence réaliste : **Groupe Boréal Synergie Inc. (« Groupe Boréal »)**.

FIL ROUGE • ARCHITECTURE

Fil rouge — Dossier d'architecture initial du Groupe Boréal (T4 2026)

Profil général : Conglomérat industriel, financier et numérique dont le siège social est établi à Montréal (Québec), comptant **14 500 employés** et générant un chiffre d'affaires annuel de **6,8 G$ CAD** en Amérique du Nord et en Union européenne.

Structure en trois divisions opérationnelles :

1. **Boréal Équipements & Logistique (BEL — 3,6 G$ CAD)** : Fabrication d'équipements électromécaniques lourds (4 usines au Québec, en Ontario et en Allemagne) et distribution de pièces (9 centres logistiques). Socle technique : `SAP S/4HANA` (avec `SAP Joule`), exécution manufacturière `Siemens Opcenter`, automates d'atelier exposés en `OPC-UA` et `MQTT`, courtiers d'événements `Confluent Kafka` et `Solace PubSub+`, partenaires logistiques raccordés en `EDI X12`.
2. **Boréal Capital & Assurances (BCA — 1,9 G$ CAD)** : Financement d'équipements, crédit-bail commercial et assurance bris de machine. Filiale assujettie à la supervision fédérale canadienne du **BSIF (ligne directrice E-23 applicable au 1er mai 2027)** et traitant des renseignements personnels soumis à la **Loi 25**. Socle technique : système central de contrats et d'indemnisation sur **`IBM i (AS/400)`** dépourvu d'API REST modernes, `Guidewire`, `Workday`, entrepôt analytique `Snowflake` et annuaire `Microsoft Entra ID`.
3. **Boréal Services Numériques (BSN — 1,3 G$ CAD)** : Plateforme infonuagique B2B de télématique industrielle et de maintenance prédictive reliant 180 000 machines déployées chez 22 000 entreprises clientes au Canada, aux États-Unis et en Europe (soumise à l'**EU AI Act** pour ses modules prédictifs et d'assistance). Socle technique : `Salesforce Sales/Service Cloud` (`Agentforce`), `ServiceNow ITSM/FSM`, `Microsoft Copilot Studio` dans Teams, et grappe Kubernetes interne hébergeant des services analytiques et des modèles ouverts.

L'état de crise à l'automne 2026 (Point zéro du Compendium) : Un audit conjoint Architecture–Sécurité diligenté après deux incidents majeurs recense **47 initiatives agentiques disparates** à travers les trois divisions, dont 19 déployées hors de tout contrôle TI (*Shadow Agents*) :

- *Incident financier* : Un agent expérimental de rapprochement d'achats chez BEL est entré dans une boucle de réessai mutuelle avec un extracteur documentaire suite à un changement de format de facture fournisseur, consommant **41 200 $ CAD** d'inférence de modèle de raisonnement en onze heures avant détection manuelle le lundi matin.
- *Incident de conformité* : Un assistant de pré-qualification de dossiers chez BCA s'exécutait au moyen d'un compte de service statique possédant des privilèges de lecture sur des tables de sinistres hors périmètre, sans journalisation de l'employé donneur d'ordre — une lacune incompatible avec la piste d'audit exigée par la `Loi 25` et par l'échéance `BSIF E-23`.
- *Paralysie opérationnelle inter-silos* : Lorsqu'une sonde télématique BSN détecte une dérive vibratoire critique sur un compresseur industriel sous contrat, quatre agents locaux existent déjà (diagnostic BSN, billetterie `ServiceNow`, contrat BCA, stock `SAP`), mais **aucun ne peut coopérer avec les autres**. Trois coordonnateurs humains passent en moyenne **46 heures** à recopier des numéros de série entre quatre écrans pour valider la garantie, réserver la pièce et dépêcher un technicien certifié.

Le mandat 2027 : Le comité exécutif confie à l'architecte en chef la conception de la **Fabrique Agentique Boréal** (*Boréal Agentic Fabric*), avec trois objectifs chiffrés à douze mois : ramener le délai de bout en bout d'une intervention prédictive sous **25 minutes** en autonomie supervisée `L3`, réduire de **55 %** le coût d'inférence par dossier traité, et réussir l'homologation réglementaire croisée `BSIF E-23` / `Loi 25` / `ISO/IEC 42001` avant le deuxième trimestre 2027.

Chaque chapitre de ce compendium prendra appui sur une brique précise de ce chantier pour illustrer, schémas et contrats de code à l'appui, comment transformer un archipel de prototypes fragiles en une architecture d'entreprise interopérable, résiliente et gouvernée.

0.6 Cartographie synthétique des standards, protocoles et cadres de référence 2027

L'un des obstacles majeurs rencontrés par les équipes d'architecture en 2026–2027 tient à la densité acronymique d'un écosystème qui s'est structuré à grande vitesse. Pour offrir dès cette ouverture une boussole stable, le tableau de référence ci-dessous positionne les **dix-huit standards techniques, cadres de sécurité et régimes réglementaires** qui traversent le compendium, en précisant leur organisme de gouvernance neutre, leur rôle exact dans la pile à six couches et les chapitres où leur implémentation est détaillée.

Standard / Cadre	Organisme de tutelle (fin 2026)	Couche principale	Fonction architecturale exacte	Chapitres clés
`MCP` (*Model Context Protocol*)	Linux Foundation (`AAIF`)	Couche 1 (Vertical)	Protocole JSON-RPC 2.0 normalisant l'accès des modèles et agents aux outils, ressources documentaires et invites métiers	Chap. 1, 4, 5, 19
`Agent Skills` & `AGENTS.md`	Linux Foundation (`AAIF`)	Couche 1 (Vertical)	Formats ouverts d'empaquetage modulaire de compétences exécutables et de consignes contextuelles de dépôt	Chap. 4, 5, 22
`Open Responses`	Linux Foundation (`AAIF`)	Couche 1 (Inférence)	Spécification d'API partagée normalisant les sorties structurées et événements d'inférence entre fournisseurs de modèles	Chap. 4, 5, 14
`WebMCP`	Écosystème Web / W3C CG	Couche 1 (Web)	Exposition native d'outils et de contexte structuré par les applications web directement au navigateur et aux agents	Chap. 5, 16
`agentgateway` & `Agent Router`	Linux Foundation (`AAIF`)	Couche 1 (Plan de données)	Passerelles AI-natives unifiant le routage multi-LLM, le multiplexage `MCP`, le proxy `A2A` et les politiques de débit	Chap. 4, 14, 20
`Apache Ossie` (*OSI*)	Apache Software Foundation	Couche 2 (Sémantique)	Standard ouvert d'échange sémantique unifiant définitions de métriques, dimensions et relations ontologiques	Chap. 8, 9, 15

Standard / Cadre	Organisme de tutelle (fin 2026)	Couche principale	Fonction architecturale exacte	Chapitres clés
A2A v1.0 (*Agent2Agent*, incl. ACP)	Linux Foundation (AAIF)	Couche 3 (Horizontal)	Protocole pair-à-pair de découverte (Agent Cards), délégation asynchrone de tâches et partage d'artefacts inter-agents	Chap. 1, 4, 6, 15
AGNTCY (OASF, SLIM, *Directory*)	Linux Foundation	Couche 3 (Réseau)	Schéma descriptif universel de capacités (OASF), annuaire fédéré et messagerie basse latence chiffrée MLS (SLIM)	Chap. 4, 6
AG-UI & A2UI / MCP-UI	Communautés Open Source	Couche 5 (Interface)	Flux bidirectionnel d'événements d'état agentique (AG-UI) et génération déclarative sécurisée de composants UI (A2UI)	Chap. 7, 25
OPC-UA & MQTT Sparkplug	OPC Foundation / Eclipse	Couche 1 & 4 (IT/OT)	Protocoles industriels normalisés permettant l'exploration sémantique et la télémétrie temps réel des équipements d'usine	Chap. 1, 17
OAuth 2.1 OBO, RFC 8693 & CIBA	IETF / Open ID Foundation	Transversal (Identité)	Échange de jetons délégués à portée atténuée (sub/act) et authentification hors bande asynchrone pour actions critiques	Chap. 18, 20
SPIFFE / SPIRE & W3C DIDs / VCs	CNCF (LF) / W3C	Transversal (Identité)	Attestation cryptographique d'identité machine (NHI) et justificatifs vérifiables de provenance ou de mandat	Chap. 7, 18
OWASP ASI01–ASI10	Fondation OWASP	Transversal (Sécurité)	Taxonomie de référence des dix risques critiques propres aux applications agentiques autonomes et multi-agents	Chap. 19, 20, 25
OpenSandbox & OpenEnv	Linux Foundation (AAIF)	Sécurité & AgentOps	Exécution isolée sécurisée du code/outils (OpenSandbox) et environnements standardisés d'évaluation/RL (OpenEnv)	Chap. 20, 22
Open Telemetry (gen_ai.*)	CNCF (Linux Foundation)	Transversal (AgentOps)	Conventions sémantiques neutres pour tracer de bout en bout appels de modèles, jetons, outils MCP et graphes A2A	Chap. 21, 23

Standard / Cadre	Organisme de tutelle (fin 2026)	Couche principale	Fonction architecturale exacte	Chapitres clés
`AP2` & `x402`	FIDO Alliance / LF (`x402`)	Couche 6 (Commerce)	Mandats cryptographiques d'intention et de panier (`AP2`) couplés au règlement financier natif sur code HTTP 402 (`x402`)	Chap. 7, 24
`ISO/IEC 42001` & `NIST AI RMF`	ISO/IEC / NIST	Couche 6 (Gouvernance)	Système de management de l'IA certifiable en amélioration continue (PDCA) et référentiels de maîtrise des risques d'agents	Chap. 24, 25
`EU AI Act`, `BSIF E-23` & `Loi 25`	UE / BSIF Canada / Québec	Couche 6 (Réglementaire)	Obligations légales contraignantes de transparence, gestion du risque de modèle (1er mai 2027), ÉFVP et supervision humaine	Chap. 1, 18, 24

Articulation logique des huit parties du compendium

La progression des chapitres qui suivent obéit à un principe d'ingénierie simple : **on ne peut orchestrer durablement que ce qui est sémantiquement et protocolairement interopérable, et on ne peut mettre en production à grande échelle que ce qui est cryptographiquement identifié, observable et économiquement borné**.

- Les **Parties I à III (Chapitres 1 à 10)** construisent le *modèle anatomique, protocolaire et sémantique* : elles définissent les acteurs, découplent le contrôle déterministe de l'inférence probabiliste, déploient la pile ouverte `MCP` / `A2A` / `AGNTCY` / `AG-UI` et résolvent l'alignement du sens métier via `Apache Ossie` et la mémoire bi-temporelle.
- Les **Parties IV et V (Chapitres 11 à 17)** bâtissent le *moteur d'exécution et d'intégration au réel* : topologies d'orchestration et de chorégraphie, exécution durable multi-jours (`Temporal`, `Restate`), sagas événementielles à compensation (`Kafka`, `Solace`), passerelles AI-natives à routage `SLM`/`LLM`, puis fédération concrète des suites SaaS (`Agentforce`, `ServiceNow`, `SAP Joule`, `Copilot Studio`), des écrans patrimoniaux sans API (`CUA`) et des ateliers industriels (`OPC-UA`, jumeaux numériques).

- Les **Parties VI à VIII (Chapitres 18 à 25)** verrouillent *l'exploitabilité industrielle, sécuritaire, financière et juridique* : identités non humaines Zero Trust, défense active contre `OWASP ASI01–ASI10`, observabilité `OpenTelemetry`, homologation par simulation τ-bench et ingénierie du chaos, FinOps orienté *Cost-per-Outcome*, conformité réglementaire 2027 et modèle organisationnel du Centre d'Excellence Agentique.

Ouvrons maintenant la **Partie I** pour établir les fondations architecturales de cette main-d'œuvre numérique d'exécution asynchrone.

PARTIE I — Fondations de l'Entreprise Agentique en 2027 : Paradigmes, Taxonomie et Maturité

Périmètre éditorial de la Partie I : 53 pages (p. 18–70) • **Chapitres 1 à 3**

L'entrée en production massive de systèmes multi-agents au sein des grandes organisations ne prolonge pas simplement la vague des assistants conversationnels de 2023–2024 : elle inverse le centre de gravité du système d'information. Tant qu'un modèle de langage répondait à un humain dans une fenêtre de clavardage, l'opérateur humain demeurait l'unique orchestrateur, le vérificateur sémantique implicite et le détenteur exclusif des droits d'écriture dans les progiciels métiers. Dès lors que des agents reçoivent des objectifs asynchrones, délèguent des sous-tâches à d'autres agents et mutent directement des systèmes d'enregistrement, chaque raccourci architectural pris à l'ère des prototypes devient un vecteur de panne systémique, de dérapage financier ou d'infraction réglementaire.

Cette première partie pose les fondations conceptuelles, taxonomiques et architecturales sur lesquelles reposent les sept parties suivantes du compendium :

- Le **Chapitre 1** analyse la transition structurelle de l'assistance synchrone centrée sur l'interface (*UI-first*) vers une main-d'œuvre numérique d'exécution asynchrone, établit la taxonomie fonctionnelle des acteurs agentiques et formalise la superposition d'un *System of Action* gouverné au-dessus des *Systems of Record* patrimoniaux.
- Le **Chapitre 2** démontre mathématiquement et empiriquement pourquoi la fiabilité d'une chaîne purement probabiliste s'effondre à l'échelle, puis introduit le patron cardinal de 2027 : le découplage strict entre plans de contrôle déterministes et cellules de raisonnement autonome bornées.
- Le **Chapitre 3** fournit un modèle de maturité opérationnel en cinq niveaux (du chaos des *Shadow Agents* jusqu'à la fédération inter-entreprises), recense les antipatterns d'adoption les plus coûteux et livre une grille de diagnostic *brownfield* directement exploitable par les équipes d'architecture d'entreprise.

Chapitre 1 — De l'assistance conversationnelle à la main-d'œuvre d'exécution asynchrone

SYNTHÈSE EXÉCUTIVE

Synthèse exécutive — Chapitre 1

- **Enjeu stratégique** : Les assistants conversationnels synchrones (génération 2023–2024) plafonnent à des gains de productivité individuelle marginaux de 5 à 12 %, car ils laissent à l'employé humain la charge intégrale de coordonner les applications, de vérifier les règles d'affaires et d'exécuter les saisies inter-systèmes. Franchir un palier de transformation exige de passer à une **main-d'œuvre numérique d'exécution asynchrone** intégrée aux flux d'événements de l'entreprise.
- **Décisions architecturales structurantes** :
  1. *Irréversible à moyen terme* : Superposer une strate explicite de **System of Action** au-dessus des *Systems of Record* existants (ERP, CRM, cœurs patrimoniaux) plutôt que d'enfouir une logique d'orchestration propriétaire à l'intérieur d'un seul progiciel.
  2. *Structurante dès le jour 1* : Imposer la séparation fonctionnelle en cinq archétypes d'acteurs (interface, spécialiste de domaine, travailleur de tâche, orchestrateur, méta-gouverneur) et interdire le modèle du « super-agent » universel.
  3. *Réversible par conception* : Le choix des modèles fondationnels (`LLM` frontières ou `SLM` spécialisés) derrière chaque agent, à condition d'isoler leurs contrats par `MCP` (outils) et `A2A v1.0` (pairs).
- **Indicateurs de gouvernance associés** : Délai de traversée de bout en bout (*Lead Time* processus), taux de résolution autonome sans reprise manuelle (*Straight-Through Agentic Processing*), taux d'escalade pertinente en *Human-on-the-Loop* (`HOTL`), et **coût complet par résultat métier validé (*Cost-per-Outcome*)**.

1.1 Anatomie évolutive (2023–2027) : pourquoi le paradigme du copilote plafonne en entreprise

L'histoire industrielle de l'informatique d'entreprise montre qu'une technologie de rupture commence systématiquement par imiter le média qu'elle remplace avant de trouver sa forme native. Les premières bases de données relationnelles

furent d'abord utilisées comme des fichiers séquentiels indexés ; les premières applications web reproduisaient des formulaires papier statiques. De la même manière, entre 2023 et 2025, l'adoption initiale des grands modèles de langage s'est presque exclusivement coulée dans le moule du **clavardage synchrone** : une boîte de dialogue latérale greffée aux outils bureautiques, aux portails intranet ou aux consoles de service client.

Ce modèle du copilote conversationnel a permis d'acculturer rapidement des millions de travailleurs du savoir, mais il s'est heurté dès 2025 à un plafond structurel de création de valeur que les directions financières ont fini par documenter : **accélérer la rédaction d'un courriel ou la synthèse d'une note interne ne réduit pas le temps de cycle d'un processus métier qui passe 92 % de sa durée en files d'attente inter-départementales, en vérifications de conformité et en rapprochements de données entre quatre progiciels incompatibles**.

Pour comprendre les exigences architecturales de 2027, il faut analyser avec précision les limites techniques qui ont conduit le marché à travers trois générations successives d'architectures.

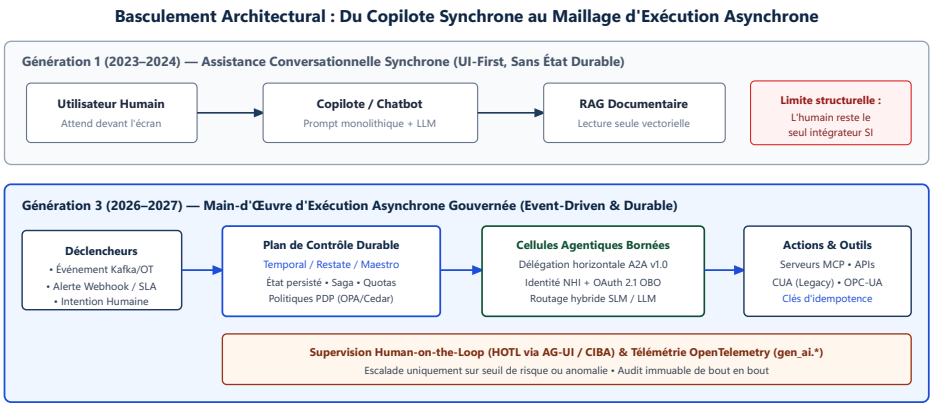


Fig. 2. – Basculement architectural de la Génération 1 (copilote synchrone centré interface) vers la Génération 3 (maillage d'exécution asynchrone gouverné).

Génération 1 (2023–2024) : Le copilote synchrone et le syndrome du « presse-papiers humain »

Dans une architecture de première génération, l'interaction obéit à une boucle requête-réponse bloquante initiée par un utilisateur devant son écran. Le système combine une consigne système (*system prompt*), l'historique immédiat de la session et quelques fragments textuels extraits d'une base vectorielle par similarité cosinus (RAG naïf).

Trois propriétés condamnent cette architecture dès qu'on tente de l'appliquer à des opérations critiques :

1. **Couplage temporel à l'attention humaine** : Rien ne se produit tant qu'un employé n'ouvre pas la fenêtre de dialogue, et l'exécution s'interrompt dès qu'il ferme son navigateur. Or, la vie opérationnelle d'une entreprise est gouvernée par des événements asynchrones — rupture de stock à 2 h du matin, alerte de capteur industriel, expiration d'un délai contractuel, réception d'un avis de règlement EDI — qui exigent une prise en charge immédiate sans présence humaine préalable.
2. **Cécité transactionnelle et intégration par copier-coller** : Limité à la lecture documentaire pour éviter les erreurs d'écriture, le copilote délègue à l'opérateur humain la traduction de sa recommandation textuelle en transactions dans `SAP`, `Salesforce` ou `ServiceNow`. L'humain sert de convertisseur manuel entre du texte non structuré et des formulaires structurés, réintroduisant délais, erreurs de saisie et fatigue cognitive.
3. **Amnésie d'état et absence de redevabilité** : Chaque conversation repart d'une feuille quasi blanche. Aucune machine à états ne garantit que deux employés posant le même problème à deux heures d'intervalle appliqueront la même politique d'entreprise.

Génération 2 (2025) : L'agent monolithique outillé et le mur de complexité

La deuxième génération a doté le modèle de langage de capacités d'appel de fonctions (*tool calling*) et d'une boucle autonome de type *ReAct* (*Reason + Act*). Un agent unique recevait un objectif, observait le résultat d'un premier appel d'API, puis décidait du prochain appel jusqu'à complétion supposée. Parallèlement, les

grands éditeurs SaaS ont lancé leurs premiers agents natifs à l'intérieur de leurs frontières applicatives respectives.

En production, cette approche monolithique s'est brisée sur quatre murs d'ingénierie :

- **Dégradation cognitive par surcharge d'outils (*Tool Overload*)** : Dès qu'un agent unique se voit exposer plus de quinze à vingt-cinq définitions d'outils hétérogènes aux schémas JSON complexes, la précision de sélection d'outil et de remplissage des paramètres chute fortement, tandis que la consommation de jetons de contexte explose à chaque tour de boucle.
- **Fragilité en mémoire vive volatile** : Exécutée dans un processus applicatif ordinaire (conteneur HTTP ou fonction sans serveur à durée de vie limitée), une boucle agentique qui échoue au huitième tour à cause d'une expiration réseau (`HTTP 504`) perd son fil d'exécution ou, en cas de réessai aveugle, réexécute des actions non idempotentes déjà commises aux tours précédents.
- **Sur-privilégiation systémique** : Pour qu'un seul agent puisse traiter un dossier de bout en bout, les équipes lui accordaient l'union de toutes les permissions nécessaires à l'ensemble des étapes (lecture CRM + écriture ERP + envoi de courriel externe), créant un rayon d'explosion maximal en cas d'injection de prompt (`OWASP ASI03`).
- **Enfermement en silos éditeurs** : Un agent construit dans le studio d'un éditeur CRM excellait sur ses objets natifs, mais devenait aveugle dès que la résolution exigeait d'inspecter un automate d'usine ou un système central d'assurance externe.

Génération 3 (2026–2027) : La main-d'œuvre multi-agents asynchrone, durable et fédérée

L'architecture de troisième génération, objet de ce compendium, abandonne l'illusion du modèle omniscient au profit des principes éprouvés des systèmes distribués critiques adaptés au raisonnement probabiliste. Le travail est réparti entre des **agents étroitement spécialisés** coordonnés par des **protocoles ouverts** (`MCP` vers les outils, `A2A v1.0` entre pairs), soutenus par un **moteur d'exécution durable** qui persiste chaque transition d'état, et supervisés par l'humain **sur exception quantifiée** (*Human-on-the-Loop*, `HOTL`).

Le tableau ci-dessous formalise les différences d'ingénierie entre ces trois générations.

Dimension technique	Gén. 1 : Copilote RAG (2023–2024)	Gén. 2 : Agent monolithique (2025)	Gén. 3 : Fabrique multi-agents (2026–2027)
Déclencheur primaire	Requête humaine interactive	Requête humaine ou tâche planifiée simple	Événement métier (`Kafka`/`Solace`), alerte `OT`, webhook, délégation `A2A` ou intention humaine
Portée d'exécution	Tour par tour, quelques secondes	Boucle unique en mémoire (secondes à minutes)	Asynchrone durable : secondes, heures ou semaines avec mise en veille (`scale-to-zero`)
Topologie cognitive	1 modèle généraliste + index vectoriel	1 grand modèle + 20 à 50 outils en vrac	Flotte spécialisée : routage hybride `SLM` + `LLM` de raisonnement (< 12 outils cohérents par agent)
Gestion des pannes	Message d'erreur affiché à l'utilisateur	Perte d'état ou doublons d'effets de bord	Journalisation déterministe (`Temporal`/`Restate`), clés d'idempotence et compensation `Saga`
Interopérabilité	Copier-coller manuel par l'opérateur	Adaptateurs propriétaires par cadriciel	Bi-couche normalisée AAIF : `MCP` (vertical) + `A2A v1.0` / `AGNTCY` (horizontal)
Identité et accès	Session interactive de l'utilisateur	Clé d'API statique ou compte de service global	Identité `NHI` (`SPIFFE`/`DID`) + délégation `OAuth 2.1 OBO` (`RFC 8693`) à portée atténuée
Rôle de l'humain	Exécuteur et validateur à 100 %	Approbateur `HITL` fréquent (goulot)	Superviseur `HOTL` sur seuil de risque (`CIBA`) et propriétaire métier de la politique
Unité de pilotage FinOps	Licence mensuelle par siège (*per-seat*)	Facture brute de jetons d'API	**Coût complet par résultat métier validé (*Cost-per-Outcome*)** plafonné par saga

1.2 Taxonomie fonctionnelle des acteurs numériques en entreprise

Une erreur récurrente lors du cadrage d'un programme agentique consiste à traiter tous les agents comme des entités architecturalement identiques ne différant

que par leur consigne système. En réalité, tout comme une architecture de microservices distingue les passerelles d'entrée, les services métiers transactionnels, les travailleurs asynchrones et les contrôleurs de sécurité, une entreprise agentique mature repose sur **cinq archétypes fonctionnels distincts**. Chacun possède des contraintes propres de latence, de choix de modèle, de droits d'identité et de protocoles.

1. Agents d'interface et de médiation (*Experience & Triage Agents*)

Positionnés à la périphérie directe des canaux humains (portails web réactifs via `AG-UI` et `A2UI`, clients collaboratifs d'entreprise, lignes vocales temps réel sur `WebRTC`), ces agents ont pour unique mission de capter l'intention, de désambiguïser la demande avec courtoisie, de maintenir la fluidité conversationnelle (souvent sous les 500 millisecondes de *Time-to-First-Token*) et de restituer l'état d'avancement.

- **Invariant architectural strict** : Un agent d'interface est directement exposé aux entrées non fiables des utilisateurs externes ou internes ; à ce titre, **il ne détient jamais de connecteur direct d'écriture vers un système d'enregistrement**. Il émet exclusivement des intentions structurées vers le plan d'orchestration ou invoque des pairs via `A2A` après filtrage de sécurité.

2. Agents spécialistes de domaine (*Domain Specialist Agents*)

Ce sont les piliers métiers de l'entreprise agentique : *Agent Conformité Garantie*, *Agent Planification Stocks SAP*, *Agent Diagnostic Vibratoire*, *Agent Rapprochement Comptable*. Conformément au principe de **gravité des données**, chaque spécialiste réside au plus près du domaine métier qu'il maîtrise, s'appuie sur l'ontologie de ce domaine (`Apache Ossie`) et ne manipule qu'un ensemble resserré de cinq à douze outils `MCP` hautement cohérents.

- **Invariant architectural strict** : Un spécialiste de domaine publie ses capacités sur l'annuaire interne via une `Agent Card A2A v1.0` versionnée et exige, à chaque invocation, un jeton `OAuth 2.1` dont la portée correspond exactement à l'opération demandée. Il ignore tout des interfaces graphiques finales et des autres divisions non pertinentes à son mandat.

3. Agents de tâche et d'extraction (*Task & Micro-Execution Workers*)

Souvent invisibles de l'extérieur, ces travailleurs éphémères accomplissent des opérations cognitives atomiques à fort volume : extraire les clauses pénales d'un contrat PDF complexe, normaliser une nomenclature d'ingénierie mal formatée, classifier la sévérité d'un journal d'erreur ou traduire une alerte technique.

- **Invariant architectural strict** : Sans état persistant entre deux appels (*stateless*), ils sont exécutés par défaut sur des **petits modèles de langage spécialisés (`SLM`)** hébergés à faible coût (voire localement pour des raisons de confidentialité), réservant l'escalade vers un modèle frontière aux seuls cas où leur score de confiance calibré tombe sous un seuil prédéfini.

4. Agents orchestrateurs et planificateurs (*Orchestrator & Planner Agents*)

Lorsqu'un objectif transversal ne peut être résolu par une séquence figée connue d'avance — par exemple réorganiser un plan d'approvisionnement suite à la fermeture soudaine d'un port maritime —, un agent planificateur décompose le problème en graphe de sous-tâches, sélectionne les agents spécialistes appropriés via le registre `OASF/A2A`, synthétise leurs retours partiels et adapte le plan face aux imprévus.

- **Invariant architectural strict** : L'orchestrateur cognitif propose et révise le plan, mais **l'exécution du graphe, les délais d'attente, le suivi budgétaire et la persistance d'état sont gouvernés par un moteur d'exécution durable déterministe** (`Temporal`, `Restate`, `Microsoft Agent Framework`). L'orchestrateur n'appelle pas directement les bases de données sous-jacentes : il délègue aux spécialistes.

5. Méta-gouverneurs et agents critiques (*Policy, Critic & Audit Agents*)

Placés en coupure ou en observation parallèle sur les flux sensibles (`L3` et `L4`), ces acteurs évaluent les plans et les sorties produits par d'autres agents avant engagement irréversible : vérification de cohérence factuelle par rapport aux pièces sources (détection d'hallucination), contrôle du respect du mandat commercial, détection de tentatives de manipulation sociale visant un approbateur humain (`OWASP ASI09`).

- **Invariant architectural strict** : Un agent critique ne remplace jamais une règle déterministe programmable en `Cedar` ou `OPA` (comme un plafond monétaire de 10 000 $ CAD, qui doit toujours être vérifié par du code déterministe infaillible) ; il complète ces règles déterministes sur les dimensions sémantiques nuancées qui échappent aux expressions booléennes classiques, et utilise un modèle issu d'une famille distincte de celle de l'agent évalué pour éviter les angles morts corrélés.

Archétype d'acteur	Profil de modèle cible	Protocoles principaux	Niveau d'autonomie	Risque principal à confiner
1. Interface & Médiation	Modèle rapide multimodal / temps réel	Entrée : `AG-UI`, `A2UI`, `WebRTC` ; Sortie : `A2A`	`L1` (aucune écriture directe)	Injection de prompt directe (`ASI01`), fuite de contexte en sortie
2. Spécialiste de domaine	`SLM` affiné domaine ou `LLM` intermédiaire	Entrée : `A2A v1.0` ; Sortie : `MCP` (5–12 outils)	`L2` à `L3` borné	Abus d'outils (`ASI02`), empoisonnement de serveur `MCP` (`ASI04`)
3. Travailleur de tâche	`SLM` compact haute cadence (lot / flux)	Appel interne RPC / file `Kafka` + schéma JSON strict	`L0` / `L1` sans état	Dérive silencieuse de qualité d'extraction sur nouveaux formats
4. Orchestrateur cognitif	`LLM` de raisonnement (*test-time compute*)	Entrée : Événement / `A2A` ; Sortie : `A2A` sous runtime durable	`L3` à `L4` encadré	Boucles coûteuses, défaillances en cascade (`ASI08`), escalade privilèges
5. Méta-gouverneur / Critique	Modèle indépendant + moteur `Cedar`/`OPA`	Inspection en ligne passerelle (`agentgateway`) / `HOTL`	Droit de veto et d'escalade	Faux négatifs par collusion de biais avec le modèle producteur

SECTEUR & RÉGLEMENTATION

Secteur Financier — Qualification des archétypes sous la ligne directrice BSIF E-23 (1er mai 2027)

Pour les banques, assureurs et sociétés de fiducie sous réglementation fédérale canadienne, l'entrée en vigueur le **1er mai 2027** de la ligne directrice **E-23 révisée du BSIF (Gestion du risque de modèle)** transforme directement cette taxonomie architecturale en outil de conformité prudentielle.

Dans un système monolithique où un seul « super-agent » interagit avec le client, évalue le risque de crédit et déclenche la mise en place contractuelle, **l'intégralité du composant hérite de la cote de matérialité maximale**, imposant une validation

indépendante lourde à chaque modification mineure du prompt d'accueil. À l'inverse, découper l'architecture selon les cinq archétypes permet :

1. **D'isoler la matérialité du risque de modèle** : l'*Agent d'interface* (`L1`) et le *Travailleur d'extraction documentaire* reçoivent une cote de risque modérée avec un cycle d'évolution agile, tandis que l'*Agent spécialiste d'octroi ou d'indemnisation* (`L2`/`L3`) fait l'objet d'une gouvernance E-23 complète (documentation des hypothèses, tests de stabilité pass^k, surveillance de dérive).
2. **D'appliquer nativement la séparation des tâches (*Segregation of Duties*, SoD)** : en associant des identités `NHI` distinctes à l'agent qui propose un règlement et au méta-gouverneur (ou superviseur humain `HOTL`) qui l'autorise, l'institution prouve cryptographiquement qu'aucun composant probabiliste unique ne peut simultanément instruire et décaisser un dossier.

1.3 Du *UI-First* au *System of Action* : refonder la stratigraphie du système d'information

Pendant deux décennies, l'urbanisation des systèmes d'information d'entreprise s'est appuyée sur la stratification popularisée par Gartner : à la base, les **Systems of Record** (ERP, grand livre comptable, SIRH, référentiels maîtres) garants de l'intégrité transactionnelle ACID ; au milieu, les **Systems of Differentiation** hébergeant les processus propres à l'entreprise ; au sommet, les **Systems of Engagement** (portails web, applications mobiles, outils collaboratifs) optimisés pour l'interaction humaine.

Dans cette architecture dite *UI-First*, chaque système d'enregistrement a été pensé autour de l'hypothèse implicite qu'un être humain dûment authentifié cliquerait sur une suite d'écrans pour accomplir une transaction. Même lorsque des API REST furent ajoutées, elles reflétaient bien souvent la structure granulaire des écrans (vingt appels `GET` et `PATCH` successifs sur des tables normalisées pour modifier une commande complexe).

En 2027, l'avènement de l'entreprise agentique insère une nouvelle strate horizontale décisive entre les systèmes d'engagement et les systèmes d'enregistrement : le **System of Action** (ou fabrique d'exécution agentique).

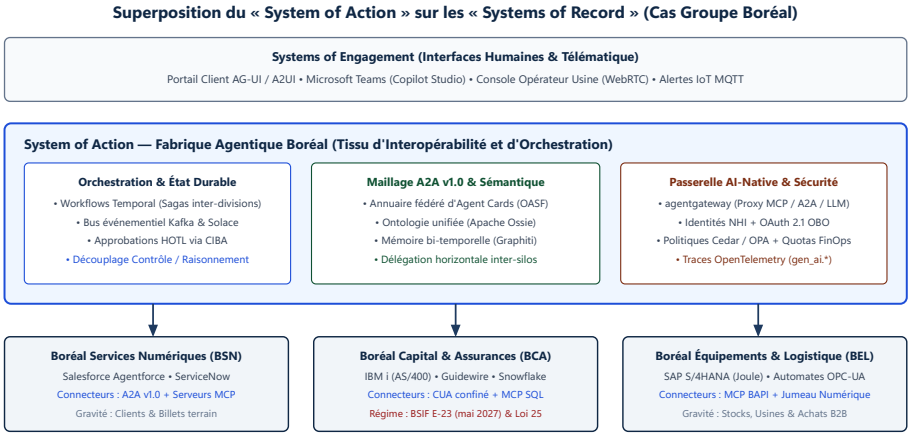


Fig. 3. – Superposition du System of Action (Fabrique Agentique Boréal) sur les Systems of Record des trois divisions opérationnelles.

Pour que cette superposition demeure saine, évolutive et auditable sur dix ans, l'architecte d'entreprise doit faire respecter **trois lois d'ingénierie fondamentales**.

Loi 1 : Inviolabilité des invariants des *Systems of Record*

Un agent ne doit jamais contourner la couche de validation métier d'un système d'enregistrement en écrivant directement dans ses tables relationnelles sous-jacentes. Si `SAP S/4HANA` ou `Guidewire` impose treize contrôles d'intégrité comptable et fiscale lors de l'émission d'un avoir, le serveur `MCP` exposant cette capacité doit invoquer l'API transactionnelle officielle (BAPI, OData métier ou service de domaine) afin que les invariants déterministes du progiciel s'appliquent intégralement. Le *System of Action* orchestre et décide *quoi* demander ; le *System of Record* demeure le gardien ultime de la cohérence interne de son registre.

Loi 2 : Orthogonalité stricte entre `MCP` (vertical) et `A2A` (horizontal)

L'une des confusions architecturales les plus fréquentes en début de projet consiste à exposer un agent autonome complexe comme un simple « outil `MCP` » d'un autre agent, ou inversement à envelopper une simple requête SQL dans un serveur `A2A`. La règle de séparation issue de la pile **Linux Foundation AAIF** est pourtant sans équivoque :

- **Utiliser `MCP` (*Model Context Protocol*) pour la connectivité verticale déterministe ou semi-structurée** : lorsqu'un agent a besoin d'invoquer une fonction typée, de lire une ressource documentaire ou d'exécuter une action bornée à comportement prévisible (rechercher un contrat, réserver une pièce en stock, calculer un tarif). Le serveur `MCP` ne négocie pas d'objectif ouvert ; il exécute une primitive documentée.
- **Utiliser `A2A v1.0` (*Agent2Agent Protocol*) pour la délégation horizontale d'objectifs entre pairs autonomes** : lorsqu'un agent confie un sous-problème nécessitant lui-même du raisonnement multi-étapes, une gestion d'état asynchrone potentiellement longue, une négociation de modalités ou le franchissement d'une frontière organisationnelle et de sécurité (par exemple demander à la division financière d'instruire une exception de garantie complexe).

Loi 3 : Tout appel mutatif circule dans une enveloppe d'action idempotente et budgétée

Dans un graphe multi-agents distribué soumis aux coupures réseau, aux expirations de jetons et aux réessais des moteurs durables, envoyer une commande nue telle que `{"action": "reserve_part", "sku": "COMP-882", "qty": 1}` est une faute professionnelle grave. Chaque délégation `A2A` ou invocation d'outil `MCP` à effet de bord doit transporter des métadonnées explicites d'idempotence, de traçabilité `OpenTelemetry`, de chaîne d'identité et de budget économique.

Les trois extraits normatifs suivants illustrent concrètement comment ces lois se traduisent dans le code et les contrats protocolaires d'une architecture de production en 2027.

Extrait 1.1 — Descripteur de capacités horizontal (`A2A v1.0 Agent Card`)

Exposé sur le point de terminaison standardisé `/.well-known/agent-card.json` (et indexé dans l'annuaire interne compatible `OASF`), ce descripteur permet à un orchestrateur de découvrir dynamiquement l'*Agent Spécialiste Garantie* de la division financière sans couplage fort à son implémentation interne :

```
{
  "protocolVersion": "1.0",
  "name": "boreal-bca-warranty-adjudicator",
  "displayName": "Agent Spécialiste Garantie & Couverture Bris (BCA)",
  "version": "2.4.1",
```

```
  "description": "Évalue l'admissibilité contractuelle, les franchises
et les plafonds de couverture pour les équipements industriels sous
contrat Boréal Capital & Assurances.",
  "url": "https://agentgateway.internal.boreal.ca/a2a/bca/warranty",
  "provider": {
    "organization": "Boréal Capital & Assurances (Division réglementée
BSIF)",
    "ownerEmail": "coe-risques-modeles@boreal.ca"
  },
  "capabilities": {
    "streaming": true,
    "pushNotifications": true,
    "stateTransitionHistory": true
  },
  "securitySchemes": {
    "borealOboAuth": {
      "type": "oauth2",
      "flows": {
        "urn:ietf:params:oauth:grant-type:token-exchange": {
          "tokenUrl": "https://login.boreal.ca/oauth2/v2.1/token",
          "scopes": {
            "bca.warranty.evaluate": "Évaluer une couverture sans
engager de décaissement",
            "bca.warranty.preauthorize": "Pré-autoriser une prise en
charge sous plafond L3 (<= 5000 CAD)"
          }
        }
      }
    }
  },
  "security": [{ "borealOboAuth": ["bca.warranty.evaluate"] }],
  "defaultInputModes": ["application/json"],
  "defaultOutputModes": ["application/json"],
  "skills": [
    {
      "id": "adjudicate-equipment-failure-coverage",
      "name": "Instruction d'admissibilité de garantie sur alerte
télématique",
      "description": "Croise le numéro de série, le code défaut
télématique et les avenants actifs sur IBM i / Guidewire afin de
statuer sur la couverture et la franchise applicable.",
      "tags": ["warranty", "bsif-e23-tier2", "equipment",
"adjudication"],
      "inputSchema": "https://schemas.boreal.ca/ossie/v2/warranty-
claim-intent.schema.json",
      "outputSchema": "https://schemas.boreal.ca/ossie/v2/warranty-
decision.schema.json"
    }
  ]
}
```

Remarquez trois détails essentiels pour un architecte et un CISO : l'URL ne pointe pas vers un pod applicatif direct mais vers la passerelle centralisée `agentgateway` ; le schéma de sécurité exige explicitement un échange de jeton `RFC 8693` à portée fine ; et les schémas d'entrée/sortie font référence au référentiel sémantique partagé (`ossie/v2`) de l'entreprise.

Extrait 1.2 — Contrat d'outil vertical (`MCP` JSON-RPC 2.0 orienté intention métier)

À l'étage inférieur, lorsque l'*Agent Spécialiste Logistique* doit réserver une pièce critique dans `SAP S/4HANA`, le serveur `MCP` n'expose surtout pas les trente tables internes du module `MM`/`SD`. Il expose un outil métier atomique, idempotent et doté d'un contrat de compensation explicite :

```
{
  "jsonrpc": "2.0",
  "id": "req-99412",
  "method": "tools/call",
  "params": {
    "name": "sap_reserve_critical_spare_part",
    "arguments": {
      "idempotencyKey": "saga-inc-2027-088412-step-reserve",
      "equipmentSerialNumber": "BOR-CMP-90441",
      "materialCode": "ROTOR-KIT-HX9",
      "quantity": 1,
      "destinationPlantOrDepot": "CA-QC-MTL-02",
      "requiredByTimestamp": "2027-03-15T18:00:00Z",
      "workOrderReference": "SN-WO-773190",
      "ttlHoldMinutes": 240
    },
    "_meta": {
      "traceparent":
"00-4bf92f3577b34da6a3ce929d0e0e4736-00f067aa0ba902b7-01",
      "compensationTool": "sap_release_spare_part_reservation"
    }
  }
}
```

Si le serveur `MCP` reçoit deux fois ce message suite à un basculement réseau du moteur d'orchestration, la clé `idempotencyKey` garantit que `SAP S/4HANA` retournera la réservation existante sans décrémenter une seconde fois le stock disponible. De plus, le paramètre `ttlHoldMinutes` implémente un bail temporel (*lease*) : si la saga globale échoue et que même la compensation est retardée, le verrouillage de stock expire proprement au bout de quatre heures.

Extrait 1.3 — Enveloppe TypeScript normative d'exécution bornée (`ActionEnvelope`)

Pour industrialiser ces garanties dans les équipes logicielles internes, la plateforme fournit un contrat typé obligatoire enveloppant toute tâche déléguée dans le *System of Action* :

```typescript
export type AutonomyLevel = "L0" | "L1" | "L2" | "L3" | "L4";

export interface DelegationHop {
  readonly actorSpiffeId: string;       // ex: spiffe://boreal.ca/ns/bsn/sa/orchestrator-maint
  readonly delegatedScope: string[];    // Portées OAuth 2.1 effectivement retenues à ce saut
  readonly issuedAtIso: string;
}

export interface ExecutionBudget {
  readonly maxTotalCostCad: number;     // Plafond dur FinOps pour la saga (ex: 1.50 $ CAD)
  readonly consumedCostCad: number;     // Coût cumulé mesuré en temps réel
  readonly maxRemainingHops: number;    // Protection déterministe anti-boucle inter-agents (TTL)
  readonly deadlineEpochMs: number;     // Échéance SLA au-delà de laquelle l'action est abandonnée
}

export interface CompensationDescriptor {
  readonly requiredOnAbort: boolean;
  readonly mcpServerUri?: string;
  readonly toolName?: string;
  readonly correlationKey: string;
}

export interface ActionEnvelope<TPayload> {
  readonly envelopeVersion: "2027.1";
  readonly sagaId: string;
  readonly stepIdempotencyKey: string;
  readonly autonomyCeiling: AutonomyLevel;
  readonly initiatingSubjectId: string; // Employé, client ou source télématique certifiée
  readonly delegationChain: ReadonlyArray<DelegationHop>;
  readonly budget: ExecutionBudget;
  readonly telemetry: {
    readonly traceId: string;
    readonly parentSpanId: string;
    readonly businessProcessCode: string;
  };
  readonly compensation: CompensationDescriptor;
```

```
  readonly payload: TPayload;
}
```

Ce simple contrat de quarante lignes élimine par construction trois causes majeures d'incidents en production : `maxRemainingHops` interdit structurellement toute boucle infinie de délégation entre pairs ; `maxTotalCostCad` permet à la passerelle d'interrompre immédiatement une exécution déviante avant dépassement budgétaire ; et `delegationChain` conserve la généalogie complète exigée par les auditeurs de sécurité.

SECTEUR & RÉGLEMENTATION

Industrie Manufacturière & Énergie (IT/OT) — Quand le System of Action rencontre la physique

Dans une banque ou un éditeur logiciel, une erreur non détectée d'un agent `L3` se solde au pire par une écriture comptable à contre-passer ou un billet mal routé. Dans une usine d'assemblage, une raffinerie ou un poste électrique connecté en `OPC-UA`, une consigne erronée envoyée au mauvais moment peut endommager une broche d'usinage de 400 000 $ CAD ou mettre en danger la sécurité physique d'un technicien.

L'architecture du *System of Action* en environnement cyber-physique applique donc une **frontière d'asymétrie stricte entre lecture et écriture OT** :

- En **lecture et diagnostic (`L1`)**, des agents spécialistes interrogent en continu les serveurs `OPC-UA`, les courtiers `MQTT Sparkplug` et les historiens de procédés pour corréler dérives thermiques, spectres vibratoires et ordres de fabrication `MES`.
- En **action corrective (`L2`/`L3`)**, aucun agent LLM n'est jamais autorisé à écrire directement un registre d'automate programmable (`PLC`). Le *System of Action* soumet obligatoirement la modification proposée (par exemple réduire la cadence d'une ligne de 12 % en attendant un remplacement de roulement) à un **jumeau numérique déterministe** qui valide les contraintes cinématiques et thermiques, puis transmet la consigne sous forme de recette pré-homologuée au système `SCADA`/`MES` avec confirmation opérateur locale si la zone est occupée.

SECTEUR & RÉGLEMENTATION

Éditeurs SaaS B2B — Concevoir un produit « Agent-Ready » en 2027

Pour les éditeurs logiciels B2B, l'émergence du *System of Action* chez leurs grands comptes transforme radicalement les critères d'achat. En 2027, une application SaaS

qui n'offre qu'une interface web humaine et une API REST granulaire mal documentée est perçue comme un silo coûteux à intégrer (forçant le client à recourir à des *Computer-Use Agents* fragiles).

Une plateforme SaaS B2B moderne expose désormais **trois surfaces citoyennes de première classe** sur le même noyau métier :

1. Une interface graphique humaine enrichie de flux réactifs `AG-UI` / `A2UI`.
2. Un **serveur `MCP` distant officiel** (sur `Streamable HTTP`, protégé par `OAuth 2.1` avec découverte dynamique de métadonnées), exposant des outils métiers idempotents à forte valeur sémantique plutôt que de simples opérations CRUD.
3. Une **façade `A2A v1.0`** permettant aux orchestrateurs des entreprises clientes de déléguer directement des tâches spécialisées à l'agent natif de l'éditeur, avec facturation transparente à l'usage ou au résultat.

1.4 Anatomie du cycle d'exécution asynchrone : régimes temporels et bascule *Human-on-the-Loop*

Passer d'un assistant synchrone à une main-d'œuvre d'exécution oblige l'architecte à concevoir explicitement la gestion du **temps**. Alors qu'une requête HTTP classique vit entre 50 millisecondes et 30 secondes, les processus d'entreprise s'étalent sur quatre ordres de grandeur temporels qui ne peuvent partager ni les mêmes protocoles de transport, ni les mêmes mécanismes de persistance.

Régime temporel	Horizon de durée	Exemples types en entreprise	Transport et infrastructure d'état requis
T1 — Temps réel interactif	150 ms à 2 s	Guidage vocal technicien (`WebRTC`), autocomplétion contextuelle, filtrage sécurité en ligne	Flux persistants (`WebRTC`, Web Sockets, `AG-UI` SSE), `SLM` à faible latence, affinité stricte de `KV-cache`
T2 — Opérationnel court	2 s à 3 min	Triage enrichi d'incident, vérification multi-sources d'un dossier client complet	`MCP` sur `Streamable HTTP`, délégation `A2A` avec streaming d'état intermédiaire
T3 — Asynchrone tactique	3 min à 24 h	Réapprovisionnement inter-dépôts, analyse de	Courtiers `Kafka`/`Solace`, webhooks `A2A` signés, moteur durable (`Restate` / `Temporal`)

Régime temporel	Horizon de durée	Exemples types en entreprise	Transport et infrastructure d'état requis
		conformité d'un appel d'offres de 400 pages	
T4 — Longue durée (Saga)	1 jour à plusieurs semaines	Instruction de sinistre assurance, intégration fournisseur B2B, litige commercial complexe	Exécution durable avec mise en veille sur disque (`awakeables`), approbation asynchrone `CIBA`, revalidation d'état au réveil

Un point de vigilance crucial concerne le régime **T4** : lorsqu'un workflow agentique se réveille après soixante-douze heures d'attente d'une signature client ou d'une expertise externe, **le monde a changé autour de lui**. Le stock vérifié trois jours plus tôt a pu être consommé, la politique tarifaire a pu évoluer, ou les droits de l'employé initiateur ont pu être révoqués suite à un changement de poste. Toute reprise après suspension longue (`resume`) doit par conséquent exécuter une **étape explicite de revalidation des préconditions critiques et des jetons d'autorisation** avant de poursuivre son graphe d'actions.

L'équation mathématique du *Human-on-the-Loop* (`HOTL`)

Face aux risques des systèmes autonomes, la réaction instinctive de nombreux comités de conformité consiste à imposer une validation humaine préalable (*Human-in-the-Loop*, `HITL` de niveau `L2`) devant chaque écriture applicative. À l'échelle d'une entreprise traitant 15 000 événements opérationnels par jour, cette stratégie échoue doublement :

1. **Engorgement de la file d'attente** : Si une tâche automatisée prend 12 secondes à la flotte d'agents mais attend 14 heures dans la boîte de réception d'un gestionnaire débordé, le gain de vélocité métier est quasi nul.
2. **Paradoxe de la complaisance cognitive (`OWASP ASI09`)** : Les études en facteurs humains démontrent qu'un opérateur contraint d'approuver 200 propositions quotidiennes dont 98 % sont correctes et rédigées dans un style persuasif développe en quelques semaines une habitude d'approbation réflexe (*rubber-stamping* en moins de trois secondes par dossier). L'organisation cumule alors la lenteur du processus manuel et l'absence réelle de filet de sécurité sur les 2 % de cas critiques.

La maturité opérationnelle en 2027 repose donc sur le passage délibéré au **Human-on-the-Loop (`HOTL`, niveau `L3`)** gouverné par une fonction de score de risque déterministe et sémantique :

$$\text{Escalade}_{\text{HOTL}}(x) = \mathbb{I}(\text{Impact}\ (x) > S_{\text{fin}} \vee \text{Incertitude}\ (x) > S_{\text{inc}} \vee \text{AlertePolitique}\ (x) = 1)$$

Concrètement, les 85 à 92 % de transactions courantes qui respectent simultanément les seuils financiers (S_{fin}), une cohérence inter-sources élevée (S_{inc} bas) et zéro alerte des règles `Cedar`/`OPA` s'exécutent sans interruption en `L3` sous télémétrie complète. Seuls les 8 à 15 % de dossiers atypiques, ambigus ou à fort enjeu financier sont routés vers un superviseur humain reposé, à qui l'interface `A2UI` présente non pas un roman généré par LLM, mais **le différentiel exact des preuves contradictoires qui ont déclenché l'escalade**.

1.5 Application au fil rouge : premier flux transversal chez Groupe Boréal

Voyons comment ces principes transforment concrètement le processus le plus douloureux identifié lors de l'audit initial du **Groupe Boréal Inc.**

FIL ROUGE • ARCHITECTURE

Fil rouge — Groupe Boréal : De 46 heures de silos manuels à 18 minutes d'exécution fédérée

Processus ciblé : Prise en charge prédictive d'une anomalie critique sur un compresseur industriel haute pression installé chez un client manufacturier québécois sous contrat de disponibilité garantie 99,5 %.

Pourquoi l'existant échouait (T4 2026 — 46 heures en moyenne) :

1. La plateforme télématique de **Boréal Services Numériques (BSN)** détectait une harmonique vibratoire anormale sur un roulement et ouvrait automatiquement un billet dans `ServiceNow`.
2. Un agent local `ServiceNow` résumait l'alerte, mais s'arrêtait là : impossible pour lui de savoir si le contrat de crédit-bail et d'assurance bris géré sur l'`IBM i (AS/400)` de **Boréal Capital & Assurances (BCA)** couvrait le remplacement préventif sans franchise, ni si le kit rotor `ROTOR-KIT-HX9` était disponible au dépôt de Montréal dans le `SAP S/4HANA` de **Boréal Équipements & Logistique (BEL)**.

3. Trois coordonnateurs humains s'échangeaient des courriels internes et des captures d'écran pendant près de deux jours, période durant laquelle 14 % des compresseurs subissaient une casse complète coûtant six fois plus cher en indemnisation et pénalités SLA.

Architecture cible déployée (Premier lot de la Fabrique Agentique Boréal — T1 2027) : L'équipe d'architecture refuse de construire un « méga-agent » ayant accès à `ServiceNow`, à l'`AS/400` et à `SAP`. Elle superpose un flux durable **Temporal** (`System of Action`) orchestrant quatre acteurs spécialisés strictement cloisonnés :

1. **Déclenchement événementiel (Régime T3)** : L'alerte vibratoire qualifiée est publiée sur le bus `Kafka` avec le schéma normalisé de l'équipement. Le moteur `Temporal` instancie une saga identifiée `saga-inc-2027-088412` dotée d'une enveloppe `ActionEnvelope` plafonnée à **1,20 $ CAD** de budget d'inférence et 4 sauts maximum.
2. **Qualification technique (`SLM` Travailleur BSN)** : Un travailleur d'analyse spectrale (`SLM` spécialisé hébergé sur le cluster interne) confirme la signature d'usure de roulement (confiance 0,96, coût 0,004 $ CAD) et identifie la nomenclature de rechange requise.
3. **Délégation horizontale en parallèle (`A2A v1.0`)** : Le workflow `Temporal` invoque simultanément via `agentgateway` deux spécialistes de domaine :
   - L'*Agent Spécialiste Garantie* de **BCA** (Extrait 1.1), qui consulte les contrats répliqués et encapsulés sous contrôle `BSIF E-23`, confirme une couverture intégrale jusqu'à 4 500 $ CAD et émet un jeton de pré-autorisation signé.
   - L'*Agent Spécialiste Stocks* de **BEL**, qui invoque l'outil `MCP` idempotent `sap_reserve_critical_spare_part` (Extrait 1.2) pour bloquer pendant 4 heures l'exemplaire disponible au dépôt de Montréal-Est.
4. **Affectation terrain et notification client** : Une fois les deux réponses positives journalisées dans `Temporal`, l'*Agent Planification Terrain* (`ServiceNow FSM`) réserve le créneau du lendemain matin d'un technicien certifié haute pression, tandis qu'une notification `A2A` informe `Salesforce Agentforce` afin que le directeur de compte dispose du contexte complet si le client l'appelle.
5. **Gouvernance `HOTL` sur exception** : Si le coût estimé de l'intervention dépasse **5 000 $ CAD** ou si le contrat comporte une clause d'exclusion ambiguë (8,4 % des dossiers observés), le moteur `Cedar` bloque l'engagement automatique, `Temporal` suspend la saga sans consommer de CPU, et une demande d'approbation asynchrone `CIBA` / `A2UI` est poussée au souscripteur BCA compétent.

Résultats mesurés sur les 60 premiers jours de production pilote :

- **Délai médian de bout en bout (hors cas d'escalade `HOTL`)** : **11 minutes** (18 minutes au 95e centile), contre 46 heures auparavant.

- **Coût complet d'inférence et d'infrastructure d'orchestration** : **0,38 $ CAD par incident résolu** (contre plus de 65 $ CAD de temps administratif interne de ressaisie).
- **Taux de casses machines évitées avant panne franche** : hausse de **+31 points**, avec piste d'audit complète `OpenTelemetry` et séparation cryptographique des privilèges entre les trois divisions.

1.6 Décision d'architecture normative et points de contrôle

Conformément à la discipline éditoriale de ce compendium, nous clôturons ce premier chapitre par la fiche de décision d'architecture fondatrice que tout comité d'architecture d'entreprise devrait adopter formellement avant d'autoriser le déploiement d'agents mutatifs, suivie de la liste de contrôle d'homologation associée.

DÉCISION D'ARCHITECTURE

ADR-001 — Superposition d'un System of Action découplé et séparation stricte MCP / A2A

- **Statut** : Acceptée (Norme fondatrice d'entreprise)
- **Contexte** : L'organisation exploite de multiples systèmes d'enregistrement hétérogènes (SaaS multi-éditeurs, bases patrimoniales, systèmes industriels) et fait face à une multiplication d'initiatives agentiques locales incapables de coopérer sans recréer des couplages point-à-point fragiles et sur-privilégiés.
- **Options évaluées** :
  1. *Centralisation dans un progiciel unique* : Forcer tous les agents métiers dans le studio d'un seul éditeur SaaS (CRM ou ITSM). **Rejetée** — verrouillage fournisseur critique, latence et coûts prohibitifs hors du domaine natif, inadaptation aux systèmes patrimoniaux et `IT/OT`.
  2. *Maillage libre d'agents généralistes* : Laisser des agents autonomes dotés de larges bouquets d'API s'appeler librement en langage naturel. **Rejetée** — fiabilité composée insuffisante, dérives budgétaires, impossibilité d'audit réglementaire (`BSIF E-23`, `Loi 25`, `EU AI Act`).

3. *Architecture stratifiée à System of Action fédéré* : Maintenir les agents spécialistes près de la gravité de leurs données respectives, imposer `MCP` pour l'accès vertical aux outils/ressources, imposer `A2A v1.0` pour la délégation horizontale inter-domaines via une passerelle contrôlée, et ancrer les flux multi-étapes dans un moteur d'exécution durable. **Retenue**.

- **Décision** : Tout système agentique de niveau `L2`, `L3` ou `L4` doit s'inscrire dans la strate *System of Action* en respectant : (a) la spécialisation en cinq archétypes fonctionnels ; (b) l'interdiction absolue d'écriture directe en base contournant la logique métier des *Systems of Record* ; (c) l'usage exclusif de `MCP` (vertical) et `A2A v1.0` (horizontal) avec transport obligatoire d'une `ActionEnvelope` idempotente et budgétée.
- **Conséquences** :
  - *Positives* : Indépendance envers les fournisseurs de modèles, confinement strict du rayon d'impact sécurité par domaine, auditabilité native de bout en bout, réutilisation des serveurs `MCP` et des spécialistes `A2A` à travers toute l'entreprise.
  - *Négatives / Coûts assumés* : Investissement initial de plateforme (passerelle AI-native, runtime durable, registre d'agents) et discipline de conception des schémas d'outils idempotents.
- **Condition de révision** : Réévaluation annuelle lors des mises à jour majeures des spécifications de la Linux Foundation AAIF.

Liste de contrôle de mise en production — Chapitre 1

Avant de passer à la conception détaillée des plans de contrôle déterministes au **Chapitre 2**, vérifiez que votre programme répond sans ambiguïté aux huit exigences suivantes :

1. **Qualification du niveau d'autonomie** : Chaque cas d'usage candidat est-il formellement classé sur l'échelle `L0` à `L4`, en appliquant la règle du maillon le plus élevé (*High-Water Mark*) sur l'ensemble de la chaîne ?
2. **Séparation des archétypes** : Aucun agent directement exposé à des entrées utilisateurs non fiables (`Interface`) ne possède-t-il de connecteur direct d'écriture vers un système d'enregistrement ?
3. **Granularité cognitive bornée** : Chaque agent spécialiste de domaine manipule-t-il un ensemble cohérent de moins de douze outils `MCP` orientés intention métier plutôt qu'un catalogue brut d'endpoints CRUD ?

4. **Orthogonalité protocolaire** : La frontière entre appel d'outil déterministe (`MCP`) et délégation d'objectif à un pair autonome (`A2A v1.0`) est-elle respectée sans détournement ?
5. **Idempotence et baux temporels** : Tout outil mutatif exige-t-il une clé d'idempotence déterministe et prévoit-il une opération de compensation ou un bail d'expiration (`TTL`) ?
6. **Plafonds d'enveloppe** : Chaque exécution transporte-t-elle un plafond dur de sauts (`maxRemainingHops`), une échéance temporelle et un budget maximal en devises ?
7. **Calibrage `HOTL`** : Les seuils d'escalade vers un superviseur humain reposent-ils sur des critères explicites de risque afin d'éviter simultanément l'engorgement opérationnel et la complaisance d'approbation (`OWASP ASI09`) ?
8. **Propriétaire nominatif** : Chaque agent spécialiste et chaque flux orchestré possèdent-ils un responsable métier et technique clairement identifié dans le registre d'entreprise ?